

KALMAN FILTER

BAYES FILTER ALGORITHM

```
1:  Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:    for all  $x_t$  do  
3:      ③  $\overline{bel}(x_t) = \int \underbrace{p(x_t | u_t, x_{t-1})}_{\textcircled{2}} \underbrace{bel(x_{t-1})}_{\textcircled{1}} dx$   
4:      ⑤  $bel(x_t) = \eta \underbrace{p(z_t | x_t)}_{\textcircled{4}} \underbrace{bel(x_t)}_{\textcircled{3}}$   
5:    endfor  
6:    return  $bel(x_t)$ 
```

3行目 ③control update, prediction



- ・ 物理モデルを用いた予測に該当
- ・ 物理モデルと制御値を用いて現在状態を予測

※②：前の状態と制御値が与えられた時、現在状態の確率分布

4行目 ⑤measurement update, correction

- ・ センサ観測値を用いて上記の予測を補正

※④：現在状態のセンサ観測値の確率分布



BAYES FILTERの限界とKALMAN FILTER

積分演算問題


- ・ Σ を使う離散値に比べて、連続値を計算するには積分が必要
- ・ 計算が複雑な多峰性関数(multimodal function)の積分問題をどう解決するか？

```
1:  Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:    for all  $x_t$  do  
3:       $\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:       $bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$   
5:    endfor  
6:    return  $bel(x_t)$ 
```

Unimodal



Bimodal



Multimodal




Kalman Filterの解決方法

- ・ 全ての確率分布が積分が可能なガウス分布で、モデルは線形モデルだと仮定
- ・ モデルが線形システムで、確率分布がガウス分布なら、Kalman Filterは最適の推定をする
- ・ 予測モデルと観測モデルの不確実性を比較し、何をもっと信頼するか？決める = Bayesと同じ

導入：KALMAN FILTERを用いた例

物体の軌跡を追跡するとき、今までの動きに基づいて次の時間の物体位置を推定できる





ガウス分布の特徴

- ・ 離散ベイズフィルタでは、予測にConvolution演算を、観測補正に掛算を使用
- ・ Convolution演算ではTotal Probability法則を用いて確率の合計を算出
⇒ガウス分布に同じ概念を適用できる

ガウス分布の特徴

- ・ ガウス分布 + ガウス分布 ⇒ ガウス分布
- ・ ガウス分布 × ガウス分布 ⇒ ガウス分布
- ・ ベクトルのガウス分布 ⇒ 一つの確率変数もガウス分布 (Marginals)
- ・ ガウス分布 ⇒ 条件付き確率もガウス分布 (Conditionals)

$$\begin{aligned}\mathcal{N}(\mu, \sigma^2) &= \|prior \cdot likelihood\| \\ &= \|\mathcal{N}(\bar{\mu}, \bar{\sigma}^2) \cdot \mathcal{N}(\mu_z, \sigma_z^2)\| \\ &= \mathcal{N}\left(\frac{\bar{\sigma}^2 \mu_z + \sigma_z^2 \bar{\mu}}{\bar{\sigma}^2 + \sigma_z^2}, \frac{\bar{\sigma}^2 \sigma_z^2}{\bar{\sigma}^2 + \sigma_z^2}\right)\end{aligned}$$



線形モデルの特徴

- ・線形モデルは、線形関数でモデルを表現可能
 - ・線形変換されたガウス分布もガウス分布
- ⇒現在Beliefがガウス分布なら、予測と補正モデルをかけた結果もガウス分布になることを保証

Next State Probability

$$x_t = A_t \underbrace{x_{t-1}}_{\text{State vector}} + B_t \underbrace{u_t}_{\text{Control vector}} + \varepsilon_t .$$

Measurement Probability

$$z_t = C_t x_t + \delta_t .$$

A_t : (n×n)行列

制御とノイズ無しで状態の変化

B_t : (n×l)行列

制御uによる状態の変化

C_t : (k×n)行列

現在の状態から観測へのマッピング

現在状態が与えられた時、観測の予測値

ε_t : 制御ノイズ。共分散はR

δ_t : 観測ノイズ。共分散はQ

制御モデルと観測モデルの確率分布

制御モデル

ガウスノイズに基づいた状態の確率分布

$$\begin{aligned} p(x_t \mid u_t, x_{t-1}) & \quad (3.4) \\ &= \det(2\pi R_t)^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_t - A_t x_{t-1} - B_t u_t)^T R_t^{-1} (x_t - A_t x_{t-1} - B_t u_t) \right\} \end{aligned}$$

観測モデル

ガウスノイズに基づいた観測の確率分布

$$p(z_t \mid x_t) = \det(2\pi Q_t)^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (z_t - C_t x_t)^T Q_t^{-1} (z_t - C_t x_t) \right\}$$

最後のBELIEFはガウス分布？

観測モデル（補正）

- ・ 観測モデルで補正されたbelがガウス分布か？を確認するためには、belの予測もガウス分布であることを証明すべき
- ・ ガウス分布×ガウス分布⇒ガウス分布

$$bel(x_t) = \eta \underbrace{p(z_t | x_t)}_{\text{Gaussian}} \underbrace{\overline{bel}(x_t)}_{?}$$

制御モデル（予測）

belの予測はガウス分布。数式の二つの確率分布が全てガウス分布であるため

- ・ 二つのガウス分布のConvolution⇒ガウス分布

$$\overline{bel}(x_t) = \int \underbrace{p(x_t | u_t, x_{t-1})}_{\text{Gaussian}} \underbrace{bel(x_{t-1})}_{\text{Gaussian}} dx$$

CONVOLUTION演算の詳細

$$\begin{aligned}
 \overline{\text{bel}}(x_t) &= \int \underbrace{p(x_t | x_{t-1}, u_t)}_{\sim N(x_t; A_t x_{t-1} + B_t u_t, R_t)} \underbrace{\text{bel}(x_{t-1})}_{\sim N(x_{t-1}; \mu_{t-1}, \Sigma_{t-1})} dx_{t-1} \\
 &= \underbrace{\eta}_{\text{normalization factor}} \int \exp \left\{ -\frac{1}{2} (x_t - A_t x_{t-1} - B_t u_t)^T R_t^{-1} (x_t - A_t x_{t-1} - B_t u_t) \right\} \\
 &\quad \exp \left\{ -\frac{1}{2} (x_{t-1} - \mu_{t-1})^T \Sigma_{t-1}^{-1} (x_{t-1} - \mu_{t-1}) \right\} dx_{t-1} \\
 &\quad \rightarrow \text{合計して } -L_t : \text{quadratic in } x_t, x_{t-1} \\
 &= \eta \int \exp \{-L_t\} dx_{t-1} \\
 &= \eta \int \exp \{-L_t(x_{t-1}, x_t) - L_t(x_t)\} dx_{t-1} \\
 &= \eta \underbrace{\exp\{L_t(x_t)\}}_{\text{Gaussian}} \underbrace{\int \exp\{-L_t(x_{t-1}, x_t)\} dx_{t-1}}_{\rightarrow \text{does not depend on } x_t} \\
 &= \eta \underbrace{\exp\{L_t(x_t)\}}_{\text{Gaussian}} \quad \text{Marginalization}
 \end{aligned}$$

最後のBELIEFはガウス分布？

全ての確率分布はガウス分布！

最初のbeliefがガウス分布なら、その次のbeliefはガウス分布を維持する

$$\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) \overline{bel}(x_{t-1}) dx$$

Gaussian

Gaussian

Gaussian

Gaussian

$$bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$$

Gaussian

Gaussian


Gaussian

- ・ ガウス分布は平均と共分散で表現可能
- ・ 以前時点の平均と共分散が現在時点ではどう変わるか？を表現できる

KALMAN FILTER

1: **Algorithm Kalman filter**($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):
2: $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$
3: $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t$ } Control Update
4: $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$
5: $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$ } Measurement Update
6: $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$
7: return μ_t, Σ_t

Kalman Gainのイメージ



KALMAN FILTER

- 1: **Algorithm Kalman filter**($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):
 - 2: $\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t$
 - 3: $\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t$
 - 4: $K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1}$
 - 5: $\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t)$
 - 6: $\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t$
 - 7: return μ_t, Σ_t
- } Control Update
- } Measurement Update

Kalman Gain


$$\mu = \frac{\bar{\sigma}^2 \mu_z + \sigma_z^2 \bar{\mu}}{\bar{\sigma}^2 + \sigma_z^2}$$

$$\mu = \left(\frac{\bar{\sigma}^2}{\bar{\sigma}^2 + \sigma_z^2} \right) \mu_z + \left(\frac{\sigma_z^2}{\bar{\sigma}^2 + \sigma_z^2} \right) \bar{\mu}$$

$$\begin{aligned} \mu &= K \mu_z + (1 - K) \bar{\mu} \\ &= \bar{\mu} + K(\mu_z - \bar{\mu}) \end{aligned}$$

$$\begin{aligned} \mu &= \frac{9\sigma_z^2 \mu_z + \sigma_z^2 \bar{\mu}}{9\sigma_z^2 + \sigma_z^2} \\ &= \left(\frac{9}{10} \right) \mu_z + \left(\frac{1}{10} \right) \bar{\mu} \end{aligned}$$

$$\begin{aligned} \mu &= \frac{\sigma_z^2 (\bar{\mu} + \mu_z)}{2\sigma_z^2} \\ &= \left(\frac{1}{2} \right) \bar{\mu} + \left(\frac{1}{2} \right) \mu_z \end{aligned}$$



非線形システムと KALMAN FILTER

世の中には非線形システムのケースが一般的
線形システムの制約があるKalman Filterでは、限界あり

$$x_t = g(u_t, x_{t-1}) + \varepsilon_t$$

$$z_t = h(x_t) + \delta_t.$$

Extended Kalman Filter

- ・ 非線形関数はnon-Gaussian分布
- ・ Kalman Filterは適用不可能

⇒ 非線形関数を近似する（微分が可能になる）

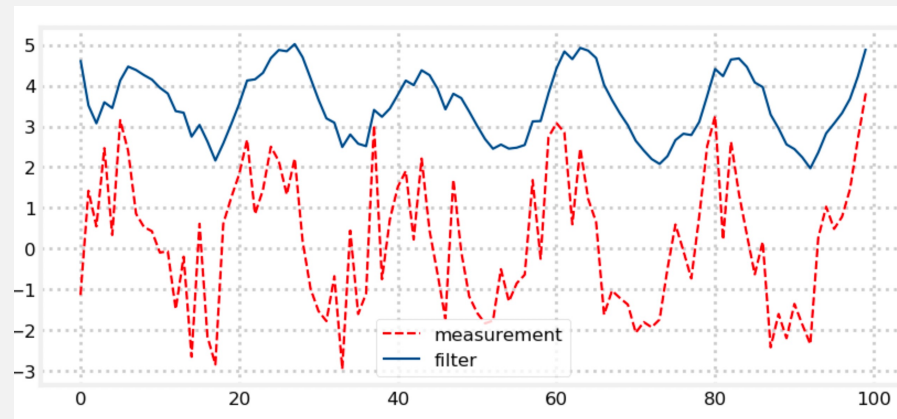
⇒ テイラー展開を用いたLocal Linearizationでbeliefの真値を近似

$$\begin{aligned} \underline{g(u_t, x_{t-1})} &\approx g(u_t, \mu_{t-1}) + \underbrace{g'(u_t, \mu_{t-1})}_{=: G_t} (x_{t-1} - \mu_{t-1}) \\ &= g(u_t, \mu_{t-1}) + G_t (x_{t-1} - \mu_{t-1}) \end{aligned}$$

$$g'(u_t, x_{t-1}) := \frac{\partial g(u_t, x_{t-1})}{\partial x_{t-1}}$$

$$\begin{aligned} h(x_t) &\approx h(\bar{\mu}_t) + \underbrace{h'(\bar{\mu}_t)}_{=: H_t} (x_t - \bar{\mu}_t) \\ &= h(\bar{\mu}_t) + H_t (x_t - \bar{\mu}_t) \end{aligned}$$

$$h'(x_t) = \frac{\partial h(x_t)}{\partial x_t}$$



EXTENDED KALMAN FILTER

1: **Algorithm Extended Kalman filter**($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):
 2: $\bar{\mu}_t = g(u_t, \mu_{t-1})$
 3: $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t$
 4: $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$
 5: $\mu_t = \bar{\mu}_t + K_t(z_t - \underline{h(\bar{\mu}_t)})$
 6: $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
 7: return μ_t, Σ_t

} Control Update

} Measurement Update

★ 違い

	Kalman filter	EKF
state prediction (Line 2)	$A_t \mu_{t-1} + B_t u_t$	$g(u_t, \mu_{t-1})$
measurement prediction (Line 5)	$C_t \bar{\mu}_t$	$h(\bar{\mu}_t)$